

## **B4. Calculus**

*Bổ sung cho bài giảng*

2019

### **Nội dung bổ sung**



1. Đạo hàm và tích phân
2. Gradient Descent



# 1. Đạo hàm và tích phân

## □ Dãy số (*sequence*)

$$f : N \rightarrow R$$

$$x_n = f(n)$$

$$\{x_n\}_n \equiv \{x_n\} \equiv x_1, x_2, x_3, \dots, x_n, \dots$$

## □ Giới hạn của dãy số (hội tụ)

$$\lim_{n \rightarrow \infty} x_n = a \quad x_n \rightarrow a, n \rightarrow \infty$$

$$\forall (\varepsilon > 0), \exists n_0 : \forall n \geq n_0 : |x_n - a| < \varepsilon$$



# 1. Đạo hàm và tích phân (tt.)

## □ Một số tính chất cơ bản của giới hạn

- Mọi dãy hội tụ đều có giới hạn duy nhất
- Mọi dãy hội tụ đều bị chặn
- Giả sử:  $\lim_{n \rightarrow \infty} x_n = a, \lim_{n \rightarrow \infty} y_n = b$ . Ta có:

$$(i) \lim_{n \rightarrow \infty} (x_n + y_n) = a + b$$

$$(ii) \lim_{n \rightarrow \infty} (c + x_n) = c + a$$

$$(iii) \lim_{n \rightarrow \infty} (c \cdot x_n) = c \cdot a$$

$$(iv) \lim_{n \rightarrow \infty} (x_n \cdot y_n) = a \cdot b$$

$$(v) \lim_{n \rightarrow \infty} \left( \frac{x_n}{y_n} \right) = \frac{a}{b}, y_n \neq 0, b \neq 0$$



# 1. Đạo hàm và tích phân (tt.)

## □ Giới hạn của hàm số

- $A$  là lân cận của  $x_0 \in \mathbb{R}$ :  $\exists(\delta > 0): (x_0 - \delta, x_0 + \delta) \subset A$
- Hàm số  $y = f(x)$  xác định trên lân cận  $A$  của  $x_0$

$$\lim_{x \rightarrow x_0} f(x) = L \quad f(x) \rightarrow L, x \rightarrow x_0$$

$$\forall(\varepsilon > 0), \exists(\delta > 0):$$

$$\forall |x - x_0| < \delta \Rightarrow |f(x) - L| < \varepsilon$$

## □ Giả sử $f(x)$ xác định trên $A$ . Hàm $f(x)$ liên tục tại $x_0 \in A$ :

$$\lim_{x \rightarrow x_0} f(x) = f(x_0)$$

$$\forall(\varepsilon > 0), \exists(\delta > 0):$$

$$\forall |x - x_0| < \delta \Rightarrow |f(x) - f(x_0)| < \varepsilon$$

- Hàm  $f(x)$  liên tục trên  $A$  nếu  $f(x)$  liên tục tại mọi  $x \in A$



# 1. Đạo hàm và tích phân (tt.)

## □ Một số tính chất cơ bản của đạo hàm

- Nếu  $f$  có đạo hàm tại  $x_0$  thì  $f$  liên tục tại  $x_0$
- Giả sử  $f(x), g(x)$  có đạo hàm tại  $x$ . Ta có:

$$(i) \quad (a.f + b.g)'(x) = a.f'(x) + b.g'(x)$$

$$(ii) \quad (f.g)'(x) = f'(x).g(x) + g'(x).f(x)$$

$$(iii) \quad \left(\frac{f}{g}\right)'(x) = \frac{f'(x).g(x) - g'(x).f(x)}{g^2(x)}$$

$$(iv) \quad (f \circ g)'(x) = f'(g(x)).g'(x)$$



# 1. Đạo hàm và tích phân (tt.)

## □ Đạo hàm của một số hàm sơ cấp

- 1)  $f(x) = a \Rightarrow f'(x) = 0$
- 2)  $f(x) = x \Rightarrow f'(x) = 1$
- 3)  $f(x) = x^\alpha, \alpha \in \mathbb{R} \setminus \{-1\} \Rightarrow f'(x) = \alpha \cdot x^{(\alpha-1)}$
- 4)  $f(x) = \frac{1}{x} \Rightarrow f'(x) = \frac{-1}{x^2}$
- 5)  $f(x) = a^x, a > 0 \Rightarrow f'(x) = \frac{1}{x \cdot \ln(a)}$
- 6)  $f(x) = e^x \Rightarrow f'(x) = e^x$
- 7)  $f(x) = \log_a(x), a > 0 \Rightarrow f'(x) = \frac{1}{a^x \cdot \ln(a)}$
- 8)  $f(x) = \ln(x) \Rightarrow f'(x) = \frac{1}{x}$
- 9)  $f(x) = \sin(x) \Rightarrow f'(x) = \cos(x)$
- 10)  $f(x) = \cos(x) \Rightarrow f'(x) = -\sin(x)$




53



# 1. Đạo hàm và tích phân (tt.)

## □ Tích phân xác định



54



## 1. Đạo hàm và tích phân


## 2. Gradient Descent

## 2. Gradient Descent



### □ Hồi quy tuyến tính (*linear regression*)

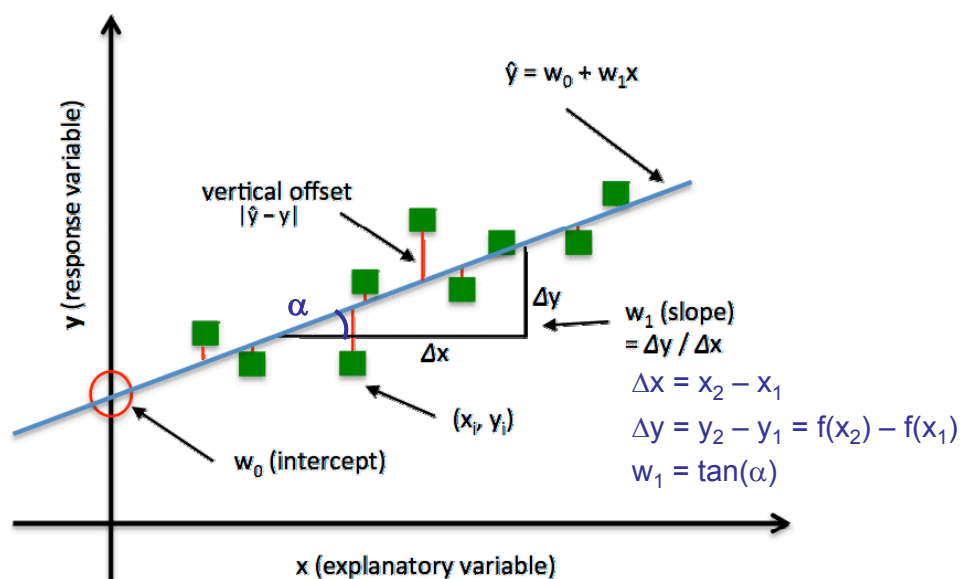
- tên khác: *linear fitting*, *linear least square*



## 2. Gradient Descent (tt.)



### □ Hồi quy tuyến tính (linear regression)



## 2. Gradient Descent (tt.)



### □ Thuật toán Gradient Descent


- local/global minimum (maximum):  $f'(x_0) = 0$
- vòng lặp tìm optimal point  $x^*$  tiến gần đến  $x_0$  (local minimum)
  - $f'(x^{(t)}) > 0$ :  $x^{(t)}$  ở bên PHẢI của  $x_0 \Rightarrow$  cần lùi sang TRÁI (A)
  - $f'(x^{(t)}) < 0$ :  $x^{(t)}$  ở bên TRÁI của  $x_0 \Rightarrow$  cần tiến sang PHẢI (B)

Tóm lại:  $x^{(t)}$  cần di chuyển NGƯỢC DẤU với đạo hàm  $\rightarrow x_0$

$$x^{(t+1)} = x^{(t)} - \rho \cdot f'(x^{(t)})$$

$$\theta^{(t+1)} = \theta^{(t)} - \rho \cdot \frac{\partial f(\theta^{(t)})}{\partial \theta^{(t)}}$$

$\rho > 0$ : **learning rate** (tốc độ học)





## 2. Gradient Descent (tt.)

### ❑ Một số hàm mất mát (loss function)

- *Regression loss*

Mean square error/Quadratic loss/L2 loss:  $MSE = \frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2$

Mean absolute error/L1 loss:  $MAE = \frac{1}{m} \sum_{i=1}^m |y_i - \hat{y}_i|$

Mean bias error:  $MBE = \frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)$

- *Classification loss*

Hinge loss/Multi class SVM loss, Cross entropy loss, ...



## 2. Gradient Descent (tt.)

### ❑ Sử dụng ma trận giả nghịch đảo

Training set:  $T = \{t^{(i)}\}_{i=1}^m, t^{(i)} = \langle x^{(i)}, y^{(i)} \rangle$

input  $x^{(i)} \in R^n$

$$X = \begin{pmatrix} x^{(1)} \\ x^{(2)} \\ \vdots \\ x^{(m)} \end{pmatrix} = \begin{pmatrix} x_{11} & x_{12} & \dots & x_{1n} \\ x_{21} & x_{22} & \dots & x_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ x_{m1} & x_{m2} & \dots & x_{mn} \end{pmatrix}$$

output  $y^{(i)} = y_i \in R$

$$Y = \begin{pmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(m)} \end{pmatrix} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{pmatrix}$$

Đặt:  $x = (x_1, \dots, x_n) \in R^n, \hat{y} = f(x) = \sum_{j=1}^n w_j x_j + w_0$

$w^T = (w_1, \dots, w_n, w_0) \in R^{(n+1)}$

$\hat{x} = (x_1, \dots, x_n, x_0) \in R^{(n+1)}, x_0 = 1, \hat{y} = \hat{x} \cdot w$

$\hat{x}_i = (x^{(i)}, 1) \in R^{(n+1)}, y_i = y^{(i)}, \forall i = 1, m$

bias



## 2. Gradient Descent (tt.)

### ❑ Sử dụng ma trận giả nghịch đảo

Training set:

$$\hat{X} = \begin{pmatrix} \hat{x}_1 \\ \vdots \\ \hat{x}_m \end{pmatrix} = \begin{pmatrix} x_{11} & \cdots & x_{1n} & 1 \\ \vdots & \ddots & \vdots & \vdots \\ x_{m1} & \cdots & x_{mn} & 1 \end{pmatrix}, Y = \begin{pmatrix} y_1 \\ \vdots \\ y_m \end{pmatrix}$$

Tìm vector cột:  $w = (w_1, \dots, w_n, w_0)^T$  sao cho  $\hat{y} = \hat{X} \cdot w \approx y$  tốt nhất

Hàm mất mát (*loss function*):

$$L(w) = \frac{1}{2m} \sum_{i=1}^m (y_i - \hat{x}_i w)^2$$

Tìm optimal point:

$$w^* = \arg \min_w L(w)$$



## 2. Gradient Descent (tt.)

### ❑ Sử dụng ma trận giả nghịch đảo

Hàm mất mát (*loss function*):

$$L(w) = \frac{1}{2m} \sum_{i=1}^m (y_i - \hat{x}_i w)^2$$

Tìm optimal point:

$$w^* = \arg \min_w L(w)$$

Xét:

$$\hat{X} = \begin{pmatrix} \hat{x}_1 \\ \vdots \\ \hat{x}_m \end{pmatrix} = \begin{pmatrix} x_{11} & \cdots & x_{1n} & 1 \\ \vdots & \ddots & \vdots & \vdots \\ x_{m1} & \cdots & x_{mn} & 1 \end{pmatrix} \quad Y = \begin{pmatrix} y_1 \\ \vdots \\ y_m \end{pmatrix}$$





## 2. Gradient Descent (tt.)

### □ Sử dụng ma trận giả nghịch đảo

$$L(w) = \frac{1}{2m} \sum_{i=1}^m (y_i - \hat{x}_i w)^2 \quad m = |T|$$

- Đạo hàm riêng của L theo  $w_i$

$$\begin{aligned} L(w_i) &= (y_i - \hat{x}_i w)^2 = (y_i - \sum_{j=0}^n \hat{x}_j w_j)^2 = (y_i - (\hat{x}_i w_i + \sum_{j \neq i} \hat{x}_j w_j))^2 = \\ &= (y_i - (\hat{x}_i w_i + C_i))^2 = y_i^2 - 2y_i(\hat{x}_i w_i + C_i) + (\hat{x}_i w_i + C_i)^2 = \\ &= y_i^2 - 2y_i \hat{x}_i w_i - 2y_i C_i + \hat{x}_i^2 w_i^2 + 2\hat{x}_i w_i C_i + C_i^2 = \\ &= -2y_i \hat{x}_i w_i + \hat{x}_i^2 w_i^2 + 2\hat{x}_i w_i C_i + D_i \end{aligned}$$



## 2. Gradient Descent (tt.)

### □ Sử dụng ma trận giả nghịch đảo

- Đạo hàm riêng của L theo  $w_i$

$$L(w_i) = -2y_i \hat{x}_i w_i + \hat{x}_i^2 w_i^2 + 2\hat{x}_i w_i C_i + D_i$$

$$\frac{\partial L(w_i)}{\partial w_i} = -2y_i \hat{x}_i + 2\hat{x}_i^2 w_i + 2\hat{x}_i C_i = 2\hat{x}_i \cdot (\sum_{j=0}^n \hat{x}_j w_j - y_i)$$

$$\frac{\partial L(w)}{\partial w} = \begin{pmatrix} \frac{\partial L(w)}{\partial w_1} \\ \frac{\partial L(w)}{\partial w_2} \\ \vdots \\ \frac{\partial L(w)}{\partial w_n} \end{pmatrix} = \frac{1}{m} \hat{X}^T (\hat{X} \cdot w - Y)$$



## 2. Gradient Descent (tt.)

### □ Sử dụng ma trận giả nghịch đảo

$$\frac{\partial L(w)}{\partial w} = \frac{1}{m} \hat{X}^T (\hat{X} \cdot w - Y) = 0$$

Giải hệ phương trình, tìm  $w$ :

$$\underbrace{\hat{X}^T \cdot \hat{X}}_A \cdot w = \underbrace{\hat{X}^T \cdot Y}_B$$

- Nếu  $\hat{X}^T \cdot \hat{X}$  khả nghịch:  $w = (\hat{X}^T \cdot \hat{X})^{-1} \cdot \hat{X}^T \cdot Y$
- Nếu  $\hat{X}^T \cdot \hat{X}$  KHÔNG khả nghịch:  $w = (\hat{X}^T \cdot \hat{X})^{\dagger} \cdot \hat{X}^T \cdot Y$   
với  $(\hat{X}^T \cdot \hat{X})^{\dagger}$  là ma trận *giả nghịch đảo* của  $\hat{X}^T \cdot \hat{X}$



## Tài liệu tham khảo



Vũ Hữu Tiệp, *Machine Learning cơ bản*, 2018